

论文阅读与实验分析报告

RepViT: Revisiting Mobile CNN From ViT Perspective

李文煜 1120233042

生物技术与人工智能

2026 年 6 月

摘要

本文阅读并分析了 CVPR 2024 发表的 RepViT 论文。RepViT 提出从 Vision Transformer (ViT) 的视角重新审视轻量级卷积神经网络, 通过将 ViT 中的高效架构设计 (如 MetaFormer 范式、Squeeze-Excite 注意力、结构重参数化) 融入 CNN, 构建了一个纯卷积的轻量模型家族。本文在 Fashion-MNIST 数据集上复现了 RepViT-M0.6 模型的训练和测试, 并与经典 LeNet-5 进行了对比实验。实验结果表明, RepViT-M0.6 以 2.17M 参数量在 Fashion-MNIST 上达到了 91.82% 的测试准确率, 较 LeNet-5 的 86.34% 提升了 5.48 个百分点, 验证了论文方法的有效性。

1 前言

1.1 问题背景

随着深度学习在计算机视觉领域的广泛应用, 在移动端和嵌入式设备上部署高性能图像识别模型成为重要的研究课题。轻量级模型需要在有限的计算资源下实现尽可能高的识别精度。

传统的轻量级模型设计主要沿两条路线发展:

1. **轻量级 CNN:** 以 MobileNet 系列 [2] 为代表, 通过深度可分离卷积 (Depthwise Separable Convolution) 降低计算量。MobileNetV3[3] 进一步引入了硬件感知的神经架构搜索 (NAS) 和 Squeeze-Excite 注意力模块。
2. **轻量级 ViT:** 以 DeiT[6]、EfficientFormer[7] 为代表, 通过优化 Transformer 架构使其适配移动端部署。

近年来, 轻量级 ViT 在精度-延迟权衡上展现出优势, 人们普遍认为 ViT 架构本身比 CNN 更适合移动端。然而, RepViT 论文挑战了这一观点, 提出一个关键问题: ViT 的优势究竟来自架构本身, 还是来自其中的高效设计元素?

1.2 相关工作

1.2.1 结构重参数化

结构重参数化 (Structural Re-parameterization) 由 RepVGG[4] 提出, 核心思想是: 训练时使用多分支拓扑以获得更好的表示能力, 推理时通过数学等价变换将多分支融合为单分支, 从而在不增加推理开销的情况下提升模型性能。RepViT 将这一技术应用于深度可分离卷积, 设计了 RepVGGDW 模块。

1.2.2 MetaFormer 范式

MetaFormer[5] 提出了一个统一的架构抽象: 将网络块分解为 **Token Mixer** (空间混合) 和 **Channel Mixer** (通道混合) 两个组件。这一范式表明, 模型的性能不仅取决于具体的 token mixer 实现 (如自注意力或卷积), 更取决于整体架构设计。RepViT 正是基于这一范式, 将 ViT 的自注意力替换为高效的深度卷积。

1.2.3 MobileNet 系列

MobileNetV1 引入深度可分离卷积, MobileNetV2 提出倒残差结构 (Inverted Residual), MobileNetV3 结合 NAS 和 SE 模块。RepViT 可以看作是对 MobileNetV3 的系统性改进, 将 ViT 中的高效设计元素逐个融入 CNN 架构。

1.3 论文主要思路

RepViT 的核心思路是: 从 **ViT 视角重新审视 CNN 架构设计**。具体而言, 论文分析了轻量级 ViT (如 FastViT、EfficientFormer) 中的高效架构元素, 发现这些元素同样可以应用于 CNN。论文基于 MobileNetV3, 逐步引入以下改进:

1. 将 MobileNetV3 的 block 对齐到 MetaFormer 范式 (token mixer + channel mixer)
2. 使用 RepVGGDW 替代原始的深度卷积 (引入结构重参数化)
3. 在适当的层引入 Squeeze-Excite 注意力机制
4. 使用 GELU 激活函数替代 Hard-Swish
5. 优化 Stem 层设计 (两步 stride=2 卷积替代单步)

最终得到的 RepViT 模型家族在 ImageNet 上以纯 CNN 架构达到了与轻量级 ViT 相当甚至更优的精度-延迟权衡。

2 论文方法的理解与解析

2.1 MetaFormer 范式与 Token/Channel Mixer

MetaFormer 将 Transformer 块抽象为两个阶段：

$$\mathbf{Y} = \mathbf{X} + \text{ChannelMixer}(\text{TokenMixer}(\mathbf{X})) \quad (1)$$

其中 $\mathbf{X} \in \mathbb{R}^{N \times D}$ 是输入特征（ N 为空间位置数， D 为通道数）。在标准 ViT 中，TokenMixer 是多头自注意力（MHSA），ChannelMixer 是 MLP。RepViT 将这一范式映射到 CNN：

- **Token Mixer** $\rightarrow$ 深度可分离卷积（空间信息混合）
- **Channel Mixer** $\rightarrow$ 倒残差 MLP（通道信息混合）

2.2 RepViT Block 设计

RepViT 定义了两种类型的 Block，分别对应 stride=1 和 stride=2 的情况（见图 1）：




图 1: RepViT Block 结构：(左) stride=1 时使用 RepVGGDW 作为 Token Mixer；(右) stride=2 时使用 DWConv($s=2$) 进行下采样。两种 Block 的 Channel Mixer 均为残差 MLP 结构。

2.2.1 stride=1 的 Block

当空间分辨率不变时, Token Mixer 使用 **RepVGGDW** 模块 (详见 2.3), 随后是可选的 Squeeze-Excite 注意力。Channel Mixer 是一个残差连接的倒残差 MLP:

$$\text{ChannelMixer}(\mathbf{x}) = \mathbf{x} + \text{PW}(\text{GELU}(\text{PW}(\mathbf{x}))) \quad (2)$$

其中 PW 表示 1×1 逐点卷积, 扩展比为 2。

2.2.2 stride=2 的 Block

当需要下采样时, Token Mixer 使用步长为 2 的深度卷积, 配合 SE 和 1×1 卷积进行通道调整。此时没有残差连接 (因为输入输出通道数可能不同)。

2.3 结构重参数化

结构重参数化是 RepViT 的核心技术之一, 主要体现在 RepVGGDW 模块中 (见图 2)。




图 2: RepVGGDW 结构重参数化示意图。训练时使用三个并行分支 (3×3 DW Conv + BN、 1×1 DW Conv、Identity), 推理时融合为单个 3×3 深度卷积。

训练时, RepVGGDW 包含三个并行分支:

1. 3×3 深度卷积 + BatchNorm
2. 1×1 深度卷积 (无 BN)
3. Identity (恒等映射)

三个分支的输出相加后通过一个共享的 BatchNorm 层:

$$\mathbf{y} = \text{BN}(\text{Conv}_{3 \times 3}^{dw}(\mathbf{x}) + \text{Conv}_{1 \times 1}^{dw}(\mathbf{x}) + \mathbf{x}) \quad (3)$$

推理时，通过数学等价变换将三支融合为单个 3×3 深度卷积：

1. 将 1×1 卷积的权重零填充为 3×3
2. 将 Identity 分支构造为权重全 1 的 3×3 卷积
3. 三组权重和偏置直接相加
4. 将最终的 BatchNorm 吸收到卷积层中

融合后的单分支推理完全等价于训练时的三支计算，但推理速度显著提升。

2.4 整体架构

RepViT 的整体架构遵循经典的层次化设计（见图 3），由 Stem 层、4 个 Stage 和分类头组成。

Stem 层： 两步 3×3 卷积（stride=2），将 28×28 下采样到 7×7 。

4 个 Stage： 每个 Stage 由若干 RepViT Block 组成，其中第一个 Block 的 stride=2 用于下采样，其余 Block 的 stride=1 保持分辨率。Stage 之间的通道数逐步增加（ $40 \rightarrow 80 \rightarrow 160 \rightarrow 320$ ）。

分类头： 全局平均池化 $\rightarrow$ BatchNorm1d + Linear。支持知识蒸馏的双分类头设计。

模型变体： 论文提出了 6 种变体（M0.6 到 M2.3），通过调整 Block 数量和通道宽度来平衡精度与延迟。本文使用最小的 M0.6 变体进行实验。

3 实验分析与结论

3.1 实验设置

3.1.1 数据集

实验使用 Fashion-MNIST 数据集，包含 70,000 张 28×28 灰度图像，分为 10 个类别：

训练集 60,000 张，测试集 10,000 张。训练时使用随机水平翻转和随机裁剪（padding=4）进行数据增强。

3.1.2 模型配置

3.2 训练结果与分析

训练过程中 RepViT-M0.6 的训练准确率和测试准确率变化曲线如图 4 所示。




图 3: RepViT-M0.6 整体架构（适配 Fashion-MNIST）。Stem 层将 28×28 输入下采样到 7×7 ，随后通过 4 个 Stage 逐步下采样到 1×1 ，最终通过全局平均池化和分类头输出 10 类预测。

表 1: Fashion-MNIST 数据集类别

标签	类别名称
0	T-shirt/top (T 恤)
1	Trouser (裤子)
2	Pullover (套衫)
3	Dress (连衣裙)
4	Coat (外套)
5	Sandal (凉鞋)
6	Shirt (衬衫)
7	Sneaker (运动鞋)
8	Bag (包)
9	Ankle boot (短靴)

表 2: 实验模型配置对比

配置项	RepViT-M0.6	LeNet-5
参数量	2,169,142	61,706
优化器	AdamW	Adam
学习率	1×10^{-3}	1×10^{-3}
学习率调度	CosineAnnealing	StepLR
训练轮次	30	20
批大小	128	64
数据增强	翻转 + 裁剪	无
激活函数	GELU	Sigmoid




图 4: RepViT-M0.6 训练曲线: 训练/测试准确率随 epoch 变化。训练使用 CosineAnnealing 学习率调度, 30 个 epoch 后测试准确率达到 91.82%。

3.3 与 LeNet-5 对比分析

本文将 RepViT-M0.6 与课程实验三中实现的 LeNet-5 在相同数据集 (Fashion-MNIST) 上进行了对比。

表 3: RepViT-M0.6 与 LeNet-5 性能对比

模型	参数量	测试准确率	F1 (Macro Avg)
LeNet-5	61,706	86.34%	86.25%
RepViT-M0.6	2,169,142	91.82%	91.82%

各类别准确率对比如图 5 所示。

从对比中可以得出以下分析:

- 整体性能:** RepViT-M0.6 的准确率显著高于 LeNet-5, 体现了现代架构设计的优势。
- 参数效率:** 虽然 RepViT 的参数量约为 LeNet-5 的 35 倍, 但通过结构重参数化等优化, 推理效率仍然较高。
- 困难类别:** 两个模型在 Shirt 类别上表现最差, 说明该类别与其他类别 (如 T-shirt/top、Coat、Pullover) 存在较高的视觉相似性。
- 架构差异:** RepViT 采用了更深的网络、SE 注意力机制和 GELU 激活函数, 这些设计元素共同提升了模型性能。




图 5: RepViT-M0.6 与 LeNet-5 各类别准确率对比。RepViT 在所有类别上均有提升，尤其在 Pullover (+11.60%)、Shirt (+18.10%) 和 Dress (+6.70%) 上提升最为显著。

3.4 结论

本文通过阅读 RepViT 论文并在 Fashion-MNIST 上进行实验，得到以下结论：

1. RepViT 成功验证了论文的核心观点：ViT 的优势更多来自其高效的架构设计元素，而非 Transformer 架构本身。将这些设计融入 CNN 可以实现更优的精度-延迟权衡。
2. 结构重参数化是一种实用的模型优化技术，在不增加推理开销的情况下通过多分支训练提升表示能力。
3. MetaFormer 范式提供了统一的架构抽象，使不同类型的模型（CNN、ViT）可以在同一框架下理解和设计。
4. 在 Fashion-MNIST 上的实验表明，RepViT-M0.6 相比经典 LeNet-5 有显著提升，验证了现代轻量级架构设计在中小规模数据集上的有效性。

参考文献

- [1] Wang A, Chen H, Lin Z, et al. RepViT: Revisiting Mobile CNN From ViT Perspective[C]. CVPR, 2024.
- [2] Howard A G, Zhu M, Chen B, et al. MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications[J]. arXiv:1704.04861, 2017.
- [3] Howard A, Sandler M, Chen B, et al. Searching for MobileNetV3[C]. ICCV, 2019.

- [4] Ding X, Zhang X, Ma N, et al. RepVGG: Making VGG-style ConvNets Great Again[C]. CVPR, 2021.
- [5] Yu W, Si C, Zhou P, et al. MetaFormer Is Actually What You Need for Vision[C]. CVPR, 2022.
- [6] Touvron H, Cord M, Douze M, et al. Training data-efficient image transformers & distillation through attention[C]. ICML, 2021.
- [7] Li Y, Yuan G, Wen Y, et al. EfficientFormer: Vision Transformers at MobileNet Speed[C]. NeurIPS, 2022.
- [8] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998.