

实验二：基于 AdaBoost 集成学习的红酒品质分类

学号：1120233042 姓名：李文煜

一、实验目的

- 理解 AdaBoost 集成学习算法的基本原理，掌握加权投票和样本权重更新机制。
- 手动实现基础 AdaBoost 二分类算法（基于 DecisionStump 弱分类器）。
- 实现 SAMME 多分类扩展算法，理解多分类下的权重调整策略。
- 分析弱分类器数量对模型性能的影响。
- 对比自实现与 sklearn 基线的性能差异。

二、实验原理

2.1 基础 AdaBoost 二分类

AdaBoost (Adaptive Boosting) 通过迭代训练弱分类器，每轮关注上一轮分类错误的样本，最终加权组合所有弱分类器的预测结果。

弱分类器：DecisionStump (单层决策树)

初始化样本权重： $w_i = 1/N$

弱分类器权重： $\alpha_t = 1/2 \cdot \ln((1 - \epsilon_t)/\epsilon_t)$

样本权重更新： $w_i \leftarrow w_i \cdot \exp(-\alpha_t \cdot y_i \cdot h_t(x_i))$

最终预测： $H(x) = \text{sign}(\sum \alpha_t \cdot h_t(x))$

2.2 SAMME 多分类扩展

SAMME (Stagewise Additive Modeling using Multi-class Exponential loss) 将 AdaBoost 扩展到多分类场景：

- 弱分类器使用 DecisionTreeClassifier(max_depth=1)
- 权重公式： $\alpha_t = \ln((1 - \epsilon_t)/\epsilon_t) + \ln(K-1)$
- 加权投票，取累计得分最高类别为预测结果

三、实验环境与数据集

3.1 实验环境

操作系统：Windows 11

编程语言：Python 3

核心库：OpenCV、PyTorch、scikit-learn、Matplotlib、NumPy 等

计算设备：CPU/CUDA

3.2 实验数据集

采用 Wine Quality (UCI ID:186) 数据集：

规模：6497 条样本，11 个理化特征 + 1 个品质评分 (3~9)

数据划分：训练集 80% (5197)、测试集 20% (1300)

标签设置：

二分类： ≥ 6 为好酒(+1)， < 6 为差酒(-1)

多分类：保留原始评分 3~9

四、实验内容与步骤

4.1 实验内容

1. 下载并预处理红酒品质数据集
2. 实现 DecisionStump 弱分类器
3. 实现 AdaBoostBinary 二分类模型
4. 实现 AdaBoostMulti (SAMME) 多分类模型
5. 完成二分类/多分类测试与结果记录
6. 生成可视化图表
7. 分析弱分类器数量对准确率的影响

4.2 实验步骤


1. 数据准备：运行 plot.py 下载并加载红酒品质人脸数据集，完成数据加载。
2. 运行全部测试并保存日志 python run_all_test.py
3. 生成可视化图表 python visualize_adaboost.py
4. 弱分类器数量对比分析 python analyze_n_clf.py

五、代码结构与框图

5.1 代码文件结构

Plain Text	
Adaboost/	
—— plot.py	# 数据集下载
—— model.py	# 核心模型实现
—— test_model_binary.py	# 二分类测试
—— test_model_multi.py	# 多分类测试
—— run_all_test.py	# 聚合测试（生成日志）
—— visualize_adaboost.py	# 可视化脚本
—— analyze_n_clf.py	# 弱分类器数量分析
—— data/	
—— wine_quality_full.csv	# 数据集
—— experiment_results.log	# 实验结果日志
—— n_clf_analysis.log	# 参数分析日志
—— confusion_matrix.png	# 10×10 混淆矩阵
—— misclassified_samples.png	# 典型错误样本可视化
—— feature_maps.png	# 卷积层特征图可视化
—— class_accuracy.png	# 各类别准确率柱状图

5.2 实验代码框图



六、实验结果

6.1 数据分布可视化

数据集质量评分集中在 5 和 6，合计占比约 60%，呈现类不平衡；二分类标签中好酒（≥6）占多数；11 个特征量纲差异较大；特征间存在相关性，其中 alcohol 与 quality 正相关，volatile_acidity 与 quality 负相关。




图 1 数据分布概览（质量分布、二分类标签、特征箱线图、相关性热力图）

6.2 二分类结果

基于 experiment_results.log

指标	值
弱分类器数量	30
准确率	73.31% (953/1300)

ROC 曲线与 Precision-Recall 曲线完整展示了二分类模型在不同阈值下的分类性能。




图 2 二分类 ROC 曲线 + Precision-Recall 曲线

6.3 多分类结果 + 混淆矩阵

基于 experiment_results.log

指标	值
弱分类器数量	50
准确率	50.46% (656/1300)




图 3 SAMME 多分类混淆矩阵

6.4 特征重要性分析

通过累加各 DecisionStump 对应的 alpha 权重得到特征重要性排序，其中 ** 酒精度（alcohol）和挥发性酸度（volatile_acidity）为最重要特征，符合葡萄酒品质评估领域知识。




图 4 基于累加 alpha 权重的特征重要性

6.5 弱分类器数量对准确率的影响

n_clf	自实现二分类	sklearn 二分类	自实现 SAMME	sklearn SAMME
1	69.23%	62.92%	44.85%	44.85%
3	69.92%	71.15%	37.54%	37.54%
5	69.62%	71.15%	42.46%	42.46%
10	71.62%	71.15%	46.85%	46.85%
15	72.92%	71.08%	50.54%	50.54%
20	72.85%	71.46%	46.54%	46.54%
30	73.31%	72.77%	48.38%	48.38%

n_clf	自实现二分类	sklearn 二分类	自实现 SAMME	sklearn SAMME
50	73.54%	73.15%	50.46%	50.46%
80	74.00%	73.92%	44.54%	44.54%
100	73.85%	74.54%	49.54%	49.54%
150	74.46%	74.54%	48.62%	48.62%

七、实验结果分析

1. 弱分类器数量的影响

二分类：随弱分类器数量增加，准确率稳步提升，增速逐渐放缓， $n>50$ 后趋于收敛。多分类：准确率波动较大，在 $n=15$ 和 $n=50$ 处达到局部最优，反映多分类任务难度更高。

2. 二分类 vs 多分类

二分类任务简单，准确率显著更高；多分类因类别数多、边界模糊、样本不平衡，准确率明显更低。

3. 自实现 vs sklearn 基线

二分类：小数量弱分类器时自实现更优，随数量增加趋于一致。多分类：自实现 SAMME 与 sklearn 结果完全一致，验证实现正确性。

4. 特征重要性解读

酒精度（alcohol）为最重要特征，挥发性酸度（volatile_acidity）次之，符合领域先验知识。

八、实验总结

1. 本次实验完整实现了 AdaBoost 算法，验证了 AdaBoost 通过迭代关注难分样本有效提升性能。

- DecisionStump 在二分类可达到 74% 以上准确率。
- SAMME 可扩展至多分类，但受数据分布限制效果有限。
- 自实现算法与 sklearn 基线一致，验证算法实现的正确。
- 弱分类器数量在 50 左右最优，继续增加收益递减。

九、附录（核心代码说明）

1. model.py: 实现 DecisionStump、AdaBoostBinary、AdaBoostMulti
2. test_model_binary.py: 二分类数据处理与测试
3. test_model_multi.py: 多分类数据处理与测试
4. run_all_test.py: 统一执行测试并输出日志
5. visualize_adaboost.py: 生成全部可视化图表
6. analyze_n_clf.py: 弱分类器数量对比实验。

具体详细可见附属压缩包 或 个人 gitee

https://gitee.com/li_fjyr/project/tree/master/PatternRecognition/Adaboost